

Prezentare Proiect TSBD - Tema 2: Question Answering peste documente (RAG Simplificat)

1. Context și Problema Abordată

În era Big Data, accesul rapid și precis la informații specifice dintr-un volum mare de documente nestructurate reprezintă o provocare majoră. Modelele de limbaj mari (LLM), deși capabile să genereze text fluent, suferă de fenomenul de „halucinație” și nu au acces la date actualizate sau private. Tema aleasă, **RAG (Retrieval-Augmented Generation)**, rezolvă această problemă prin combinarea capacității de generare a AI-ului cu precizia unei căutări vectoriale într-o bază de date locală.

2. Obiectivele Proiectului

- Implementarea unui sistem de tip Question-Answering (QA) capabil să răspundă la întrebări despre geografie și istoria Europei.
- Utilizarea capabilităților native de **AI Vector Search** ale Oracle Database 23ai.
- Integrarea modelelor de embedding și generare de la Google (Gemini).
- Crearea unei interfețe utilizator intuitive pentru interacțiunea cu datele.

3. Arhitectura Soluției

Sistemul este construit pe o arhitectură modulară, separând colectarea datelor, procesarea lor și interfața de comunicare.

Componentă	Tehnologie utilizată	Rol
Baza de date	Oracle Database 23ai	Stocarea vectorială și căutarea de similaritate.
Backend API	FastAPI (Python)	Gestionarea cererilor și orchestrarea fluxului RAG.
Embeddings / LLM	Google Gemini (API)	Transformarea textului în vectori și generarea

Componentă	Tehnologie utilizată	Rol
		răspunsurilor.
Orchestrare AI	LangChain	Legarea bazei de date cu modelul de limbaj.
Frontend	HTML5, CSS3, JS	Interfața de chat pentru utilizator.

4. Implementarea Tehnică

4.1. Colectarea Datelor (Scraping)

Sistemul include un script de web scraping care extrage automat informații de pe Wikipedia pentru 23 de puncte de interes din Europa. Datele sunt stocate inițial sub formă de text brut în corpus.txt.

4.2. Ingestia și Vectorizarea

Procesul de ingestie împarte textul în fragmente (chunks). Fiecare fragment este trimis către modelul GoogleGenerativeAIEmbeddings, care returnează un vector numeric reprezentând semnificația semantică a acelui text. Acești vectori sunt salvați în Oracle Database 23ai folosind tipul de date nativ VECTOR.

4.3. Fluxul RAG (Retrieval-Augmented Generation)

1. Utilizatorul introduce o întrebare.
2. Întrebarea este transformată într-un vector (Embedding).
3. Sistemul caută în Oracle cele mai relevante fragmente de text (Similarity Search).
4. Fragmentele găsite sunt trimise modelului Gemini ca și context.
5. Gemini generează un răspuns precis, bazat strict pe datele furnizate.

5. Concluzii și Avantaje

Utilizarea Oracle 23ai pentru Vector Search oferă un avantaj major: posibilitatea de a rula interogări vectoriale alături de date relaționale clasice într-un singur sistem robust. Această soluție elimină necesitatea unei baze de date vectoriale separate (precum Pinecone sau Milvus), reducând complexitatea infrastructurii.